

Segmentation frugale des IRM cérébrales de nourrissons en phase isointense

Hackathon SCIA 2026 — sujet 2, challenge MICCAI iSeg-2017

Jules Lange

Arthur Goullet de Rugy

septembre 2026

Résumé

À six mois, la myélinisation est à mi-course et substance grise et substance blanche ont presque la même intensité : aucune méthode fondée sur la valeur d'un point ne peut fonctionner. Nous segmentons les trois tissus des IRM T1 et T2 du challenge MICCAI iSeg-2017 en déplaçant l'information des poids appris vers des descripteurs non appris et non locaux — au premier rang desquels un arbre des formes tridimensionnel auto-dual, dont on remonte la branche de chaque voxel vers ses ancêtres à quatre échelles d'aire — puis en les donnant à une régression logistique à deux étages reliés par de l'auto-contexte. En leave-one-out sur les dix sujets annotés, cette configuration atteint un Dice moyen de 0,8399 pour 939 paramètres appris, et une variante à 163 paramètres en atteint encore 0,8036. Soumise au serveur d'évaluation du challenge, elle obtient officiellement 0,8445 sur les treize sujets de test — soit 91 % du Dice de la méthode classée première, qui emploie 1,55 million de paramètres. Nous montrons pourquoi le rapport brut du Dice au nombre de paramètres ne peut pas servir de critère de sélection, nous lui substituons une lecture en ordres de grandeur, assez grossière pour ne dépendre d'aucune convention de comptage, et un front de Pareto ; et nous rapportons trois résultats négatifs : l'auto-dualité de l'arbre des formes ne produit aucun gain de Dice distinguable, notre post-traitement topologique dégrade la segmentation parce qu'il repose sur une hypothèse anatomique fautive aux ventricules, et la quantification à 64 niveaux ne fait économiser rien de mesurable. Notre leave-one-out annonçait 0,8399 là où le serveur rend 0,8445 : l'estimation interne n'était pas optimiste.

1 Introduction

La segmentation d'une IRM cérébrale en liquide céphalo-rachidien, substance grise et substance blanche est le point de départ de presque toute étude du développement du cerveau. Épaisseur corticale, volumes tissulaires, courbes de croissance, cartes de myélinisation : toutes ces mesures se calculent sur une carte de tissus, et aucune ne vaut mieux que la segmentation dont elle part. Tracée à la main par un expert, une telle carte demande plusieurs heures par cerveau. Le challenge MICCAI iSeg-2017 (Wang et al. 2019) fournit pour ce problème des volumes T1 et T2 de nourrissons de six mois, avec dix sujets annotés.

Six mois est précisément l'âge où le problème devient difficile. La myélinisation est à mi-course, et la substance grise et la substance blanche ont presque la même intensité : c'est la phase isointense. La figure 1 la montre et la chiffre. Sur les dix sujets annotés, les distributions d'intensité des deux tissus se recouvrent à $0,701 \pm 0,048$ en T1 et à $0,867 \pm 0,041$ en T2, au sens du coefficient de recouvrement défini en figure 1. L'estimateur est légèrement pessimiste, et nous l'avons mesuré : sur deux moitiés tirées au hasard des seuls voxels de substance grise, dont le recouvrement vrai vaut 1, il rend 0,991. L'écart est donc réel. La conséquence est directe. Sur un problème à deux classes d'effectifs égaux, la meilleure règle de décision concevable fondée sur la seule intensité d'un voxel se trompe sur la moitié de l'aire de recouvrement : son exactitude plafonne à 65,0 % en T1




Figure 1. La phase isointense, sur le sujet 3 et une coupe axiale au niveau des ventricules latéraux. (a) T1, (b) T2, (c) segmentation manuelle de référence, (d) histogrammes des intensités de la substance grise et de la substance blanche, pour les deux modalités, sur l'ensemble du volume. L'aire sombre est le recouvrement, mesuré par $OV_L = \sum_b \min(p_{SG}(b), p_{SB}(b))$ où p_{SG} et p_{SB} sont les histogrammes normalisés des deux tissus sur 256 classes réparties linéairement sur l'étendue des intensités intra-masque. Il vaut 0 pour deux distributions disjointes et 1 pour deux distributions identiques. Le sujet est celui dont les quatre recouvrements mesurés sont les plus proches de la moyenne des dix ($|z| \leq 0,32$), et la coupe est celle qui maximise l'interface entre les deux tissus.

et à 56,6 % en T2. Même en lisant les deux modalités conjointement, le plafond monte seulement à 69,3 %. Aucune méthode fondée sur la valeur d'un point ne peut fonctionner ici. L'information doit venir d'ailleurs : de la géométrie locale, de la position anatomique, et de la façon dont les régions s'emboîtent les unes dans les autres.

Le critère du hackathon met le Dice obtenu en regard du nombre de paramètres appris. Ce rapport défend une seule affirmation, et chaque section y contribue : sur la segmentation de cerveaux de nourrissons en phase isointense, on atteint une fraction substantielle du Dice des méthodes publiées avec trois à quatre ordres de grandeur moins de paramètres, en déplaçant l'information des poids appris vers des descripteurs géométriques et hiérarchiques calculés à la volée. Notre configuration la plus performante, celle qui ajoute l'auto-contexte décrit en section 3.4, obtient **un Dice moyen de 0,8445 pour 939 paramètres appris**, chiffre rendu par le serveur d'évaluation du challenge sur ses treize sujets de test. La méthode classée première du même challenge en emploie un million et demi pour un Dice de 0,9283 : nous en atteignons 91 %, quatre tranches d'ordre de grandeur plus bas.

La suite est organisée ainsi. La section 2 pose les données, la limite d'évaluation qu'elles imposent, et explique pourquoi nous lisons le critère du hackathon en ordres de grandeur plutôt qu'en ratio brut. La section 3 décrit la méthode : le principe de déplacement de l'information, les six blocs de descripteurs, l'arbre des formes et la remontée de branche, le classifieur, et la convention de

comptage des paramètres. Les sections suivantes donnent le protocole, les résultats et la discussion.

2 Position du problème et métrique

Le jeu iSeg-2017 comprend dix sujets annotés et treize sujets sans annotation publique. Chaque sujet fournit un volume T1 et un volume T2 de $144 \times 192 \times 256$ voxels de 1 mm isotrope, et, pour les dix premiers, une carte de référence à trois tissus tracée manuellement. Toute notre mise au point est donc un leave-one-out sur dix sujets : c'est peu, et le protocole statistique de la section 4 en tire les conséquences.

Les treize sujets restants n'ont pas de vérité terrain publique, mais ils ne sont pas inutilisables pour autant : **nous avons soumis nos segmentations au serveur du challenge, et la section 5 donne le score officiel qu'il a rendu.** Nos chiffres sont donc comparables aux scores publiés, sur exactement les mêmes sujets et avec exactement le même évaluateur. C'est ce qui distingue une comparaison d'une analogie, et nous ne nous en serions pas passés.

Le critère du hackathon met le Dice en regard du nombre de paramètres appris, sans préciser comment. Nous prenons pour hypothèse qu'il s'agit du Dice rapporté à l'**ordre de grandeur** du décompte, et non à sa valeur exacte. Cette section justifie ce choix, parce qu'il n'est pas neutre : il change le classement, et il change ce que le rapport doit prouver.

Le ratio brut ne tient pas. Le Dice croît lentement, à peu près logarithmiquement, avec le nombre de paramètres, tandis qu'un dénominateur linéaire croît linéairement. Le quotient est donc systématiquement maximisé par le plus petit modèle de la liste, quelle que soit sa qualité, et poussé à sa limite il désigne le classifieur qui prédit partout la classe majoritaire.

Nous avons fait le calcul sur nos propres configurations plutôt que de le supposer, et le tableau 1 le donne. Sur nos douze configurations réelles, **le ratio brut s'étale d'un facteur 5,5 alors que le Dice ne s'étale que d'un facteur 1,05** : il mesure la taille du modèle et presque rien d'autre. Notre configuration la plus frugale, qui a le plus mauvais Dice de toutes, obtient le meilleur ratio brut des configurations réelles ; notre configuration la plus performante arrive dernière sur treize. Et le classifieur dégénéré, qui mémorise un seul nombre — l'indice du tissu majoritaire des neuf sujets d'entraînement — obtient un Dice moyen de $0,214 \pm 0,008$ et un ratio brut cent dix-huit fois supérieur à celui de notre configuration finale. Une métrique qui classe ce modèle premier n'est pas une métrique de sélection.

La lecture en ordres de grandeur ne fait pas la même erreur, parce qu'elle est plus grossière. Elle ne compare que la tranche, c'est-à-dire la puissance de dix. Passer de 400 à 700 paramètres ne change pas d'ordre de grandeur : les deux modèles sont à quelques centaines, et le critère ne les départage pas. Il n'a pas à le faire — à l'intérieur d'une tranche, c'est le Dice qui décide.

Le tableau 1 montre ce que cela donne : **nos douze configurations réelles sont toutes dans la même tranche, 10^2 , de 163 à 939 paramètres.** Le critère est donc muet sur notre propre famille, et c'est le Dice qui désigne l'auto-contexte, à 0,8399. Il ne parle que lorsque la tranche change, et c'est le cas deux fois : contre le challenge, dont les méthodes publiées sont en 10^6 et 10^7 , quatre à cinq tranches au-dessus ; et contre le classifieur dégénéré, quatre tranches en dessous, dont le Dice de 0,21 l'élimine immédiatement — ce qu'aucun ratio brut ne faisait.

Tableau 1. Extrait de `report/assets/ratio.md`, où figurent les treize configurations. Le classement est celui du ratio brut, décroissant : il place en tête le modèle à un paramètre et en queue notre meilleur Dice. La colonne « tranche » montre pourquoi la lecture en ordres de grandeur ne se laisse pas prendre : elle ne distingue pas 163 de 939, et distingue franchement 10^2 de 10^6 . La ligne du challenge combine le Dice officiel du serveur et un compte de paramètres publié (Wang et al. 2019) ; elle n’est pas évaluée sur les mêmes sujets que les nôtres.

configuration	paramètres		Dice moyen	Dice / paramètres
classifieur dégénéré : majoritaire partout	1	10^0	0,2139	$2,14 \cdot 10^{-1}$
sélection des 40 meilleures colonnes	163	10^2	0,8036	$4,93 \cdot 10^{-3}$
A+B+C, sans morphologie (référence)	252	10^2	0,8055	$3,20 \cdot 10^{-3}$
palier 0 : max-tree + min-tree	324	10^2	0,8156	$2,52 \cdot 10^{-3}$
palier 2 : arbre des formes + remontée	408	10^2	0,8154	$2,00 \cdot 10^{-3}$
configuration finale : tous les blocs	456	10^2	0,8276	$1,81 \cdot 10^{-3}$
palier 1 : max-tree + min-tree + remontée	564	10^2	0,8191	$1,45 \cdot 10^{-3}$
finale + auto-contexte	939	10^2	0,8399	$8,94 \cdot 10^{-4}$
MSL_SKKU, 1 ^{re} du challenge	1 550 000	10^6	0,9283	$5,99 \cdot 10^{-7}$

Ce que cette lecture ne répare pas, et que nous préférons dire : elle ne classe rien à l’intérieur d’une tranche, donc elle ne peut pas servir seule. Elle dit seulement où poser la question du Dice. C’est pourquoi nous ne présentons jamais une tranche sans le Dice qui va avec, et pourquoi le front de Pareto reste le cadrage principal.


Deux cadrages complètent cette lecture, et tous deux apparaissent en section 5. Le premier est le front de Pareto dans le plan (nombre de paramètres, Dice) en abscisse logarithmique, où nos configurations et les entrées publiées du challenge sont placées côte à côte ; c’est le seul cadrage qui rende visible un compromis au lieu de le résumer par un quotient. Le second est la comparaison d’ordre de grandeur elle-même. La méthode arrivée première du challenge, un réseau densément connecté à quarante-sept couches, compte $1,55 \cdot 10^6$ paramètres appris ; le chiffre est donné par l’article de synthèse du challenge lui-même (Wang et al. 2019). Les autres participations ne publient pas toutes le leur, mais les architectures que le même article décrit — VGG-16 transféré, U-Net 3D à cinq niveaux de sous-échantillonnage, V-Net augmenté — situent l’ensemble entre 10^6 et 10^8 paramètres. Cette seconde borne est une estimation d’ordre de grandeur déduite des architectures et non un compte publié : elle est signalée comme telle partout où elle apparaît, y compris sur le front de Pareto. Nous en avons quelques centaines, soit trois à quatre ordres de grandeur de moins. Enfin, à l’intérieur de notre propre famille de configurations, aucune différence de Dice n’est affirmée sans comparaison appariée sur les mêmes dix sujets, avec test de Wilcoxon, taille d’effet et nombre de sujets améliorés, selon le protocole de la section 4.

3 Méthode

3.1 Principe

La segmentation est traitée comme une classification voxel par voxel. Chaque voxel du masque cérébral devient une ligne d’un tableau, décrite par des colonnes calculées à la volée sur le sujet lui-même, et un classifieur minuscule lit cette ligne pour prédire un tissu. Le principe qui gouverne toute la construction tient en une phrase : tout ce qui se recalcule sur le sujet courant est gratuit, tout ce qui se mémorise du jeu d’entraînement coûte.

Ce principe a une conséquence libératrice. Un descripteur peut être aussi élaboré qu’on le veut — une convolution multi-échelle, une transformée de distance, un arbre hiérarchique complet —



En accent et en trait épais : la seule étape qui mémorise le jeu d'entraînement. Tout le reste se recalcule sur le sujet segmenté.

Figure 2. Le pipeline de la configuration finale. Les six blocs de descripteurs produisent 151 colonnes par voxel, toutes recalculées sur le sujet courant. La standardisation des colonnes est elle aussi intra-sujet. Seule la régression logistique mémorise quelque chose du jeu d'entraînement, et c'est elle seule qui compte au décompte des paramètres.

sans rien coûter au décompte, du moment qu'il se recalcule intégralement sur le sujet qu'on est en train de segmenter et qu'il ne transporte aucune valeur issue des autres sujets. Ce qui coûte, c'est uniquement ce qu'il faudrait sérialiser pour segmenter un nouveau sujet. Dans notre pipeline, une seule étape est dans ce cas. La figure 2 la met en évidence.

3.2 Les six blocs de descripteurs

Chaque bloc est présenté par l'information qui manque aux précédents. Aucun n'a de paramètre appris, ce que la suite de tests vérifie mécaniquement (section 4).

A — intensités (6 colonnes). Ce que la figure 1 établit, c'est qu'aucune modalité ne sépare seule. Ce qui sépare un peu mieux, c'est leur comportement conjoint : le couple (T1, T2) recouvre à $0,615 \pm 0,027$ contre 0,701 pour le T1 seul et 0,867 pour le T2 seul. Le gain est réel et il est modeste. Le bloc livre donc six colonnes que le classifieur lit ensemble : les deux modalités z-scorées dans le masque, leurs rangs percentiles, leur différence, et un ratio normalisé. Le ratio ne sert pas à séparer seul : mesuré avec le même estimateur, il recouvre à 0,831, donc davantage que le T1 pris isolément. Il fournit une coordonnée normalisée par sujet, que le classifieur croise avec les cinq autres colonnes. La normalisation par la médiane intra-masque de chaque modalité, avant le ratio, n'est pas cosmétique : le gain d'acquisition varie d'un sujet à l'autre et d'une modalité à l'autre, et un ratio sur intensités brutes s'effondre sur le sujet 7.

B — gaussiennes (68 colonnes). Une intensité ne dit rien de la forme locale du signal. Un voxel au sommet d'une crête, un voxel dans une nappe fine et un voxel au milieu d'un bloc homogène peuvent avoir la même valeur. Ce bloc décrit le voisinage à cinq échelles, $\sigma \in \{0,5, 1, 2, 4, 8\}$ mm : lissage, norme du gradient et laplacien normalisés en échelle, valeurs propres de la hessienne triées par module croissant, et différences de gaussiennes entre échelles consécutives. Le tri des valeurs propres rend le descripteur invariant par rotation. Au bord du masque, la convolution est normalisée par le masque lissé, sinon la marche entre le cerveau et le vide serait lue par les dérivées comme une structure anatomique.

C — spatial (9 colonnes). La position dans le crâne est un a priori anatomique gratuit, et les blocs précédents l'ignorent. Le liquide céphalo-rachidien occupe la périphérie et les ventricules ; les proportions de tissus varient fortement du centre vers le cortex. Le bloc fournit les coordonnées normalisées par la boîte englobante du masque, la distance euclidienne au bord du masque, la

distance au plan sagittal médian, et des coordonnées sphériques autour du centroïde. Le plan médian et les axes sont estimés par analyse en composantes principales des coordonnées des voxels du masque du sujet. Tout est relatif au sujet : ni atlas, ni recalage, ni valeur transportée.

D — morphologie (52 colonnes). Les trois blocs précédents sont locaux. Aucun ne peut exprimer qu'un voxel appartient à une région mince enveloppant une région beaucoup plus grande. C'est l'objet de la section 3.3.

E — symétrie (4 colonnes). Le point contralatéral est une information que rien d'autre n'apporte. Le cerveau est presque symétrique par rapport au plan sagittal médian, et un voxel et son miroir appartiennent le plus souvent au même tissu. Une asymétrie locale d'intensité signale donc une frontière ou une structure impaire, comme les ventricules ou la scissure interhémisphérique. Le bloc donne, pour chaque modalité z-scorée, l'intensité au point miroir par interpolation trilinéaire et l'écart entre le voxel et son miroir. Le plan est celui du bloc C.

F — contexte (12 colonnes). Il reste à décrire le voisinage immédiat pour un coût négligeable. Le bloc calcule la moyenne et l'écart-type locaux des rangs percentiles des deux modalités, dans des boîtes de rayon 1, 2 et 4 voxels, normalisés par le masque pour ne pas être biaisés au bord. Il lisse les données, et non des probabilités apprises : c'est ce qui le distingue de l'auto-contexte de la section 3.4, et ce qui le rend gratuit.

3.3 Arbre des formes et remontée de branche

Les blocs A à C lisent tous un voisinage de quelques millimètres au plus. Or à six mois la frontière entre substance grise et substance blanche ne se voit pas localement : c'est exactement ce que la figure 1 mesure. Ce qui distingue un ruban cortical de la substance blanche sous-jacente n'est pas le contraste local, c'est le fait que le ruban est une forme mince enveloppant une forme beaucoup plus grande. C'est un énoncé sur l'inclusion des régions les unes dans les autres, à toutes les échelles, et aucun filtre local ne sait l'exprimer.

L'arbre des formes est la structure qui l'exprime. On seuille l'image à tous les niveaux, dans les deux sens, et on sature les composantes obtenues en bouchant leurs trous. Ces formes saturées ne se croisent jamais : deux d'entre elles sont disjointes ou emboîtées. Elles s'organisent donc en un arbre unique dont la racine est l'image entière (Monasse et Guichard 2000), et que l'on sait calculer en temps quasi linéaire en dimension quelconque (Géraud et al. 2013). Chaque voxel appartient à une branche complète, de la plus petite forme qui le contient jusqu'à la racine. La figure 3 montre l'emboîtement et l'arbre correspondant sur une image de synthèse, calculés par *higra* (Perret et al. 2019) avec la même fonction que celle utilisée en trois dimensions.

L'arbre des formes est auto-dual : l'arbre de f et celui de $-f$ sont le même. Une forme sombre incluse dans une forme claire est un nœud au même titre qu'une forme claire incluse dans une forme sombre, ce que la figure 3 illustre. La propriété nous sert directement, parce que le T1 et le T2 ont des contrastes inversés et qu'un seul arbre par modalité les décrit de la même façon. La solution de repli, un max-tree accompagné d'un min-tree (Salembier, Oliveras, et Garrido 1998), demande deux arbres et deux fois plus de colonnes pour les mêmes attributs.

Il faut être précis sur ce que nous conservons et ce que nous abandonnons. L'arbre des formes théorique est invariant à toute transformation croissante de l'intensité. Nous ne conservons pas cette invariance. Nous quantifions l'image sur 256 niveaux répartis linéairement entre les percentiles 1 et 99 intra-masque. Sous une transformation affine de l'intensité, gain et décalage d'acquisition, ces percentiles se transforment de la même façon, l'image quantifiée est identique et tout ce qui en découle l'est aussi : l'invariance affine est exacte. Sous une transformation croissante quelconque, une correction gamma par exemple, les classes de quantification ne coïncident plus avec les lignes de niveau, et les attributs qui lisent des altitudes — contraste, dynamique, résidu — changent. La variante qui conserve cette invariance, une quantification par




Figure 3. Arbre des formes d’une image de synthèse à cinq niveaux, calculé et non dessiné à la main. (a) Les formes saturées, en pointillé blanc, et en trait plein la branche du voxel p . (b) L’arbre d’inclusion, avec en ordonnée l’aire des nœuds en échelle logarithmique et en accent la branche de p . Le remplissage d’un nœud rappelle le niveau de gris de la forme correspondante : la forme sombre est emboîtée entre deux formes claires sur la même branche, ce qu’aucun max-tree ni min-tree ne produirait. Les lignes horizontales sont les seuils d’aire ; le premier ancêtre $a(T_i)$ de la remontée de branche est le premier nœud de la branche situé au-dessus de la ligne T_i .

rang percentile, existe dans le code et nous l’avons mesurée en leave-one-out : elle perd 0,0018 de Dice moyen, avec 2 sujets améliorés sur 10 et $p = 0,064$, ce qui ne la distingue pas du bruit (section 5). Nous gardons la quantification linéaire parce que les volumes iSeg sont déjà corrigés en inhomogénéité de champ, ce qui rend l’invariance non linéaire peu utile ici, et parce que les niveaux linéaires préservent les amplitudes de contraste que les attributs exploitent. Nous revendiquons donc l’auto-dualité et l’invariance affine, et nous ne revendiquons pas l’invariance au contraste.

Chaque nœud de l’arbre porte six attributs sans dimension, du même genre que ceux des filtres par attribut (Breen et Jones 1996) : le logarithme de son aire rapportée au volume du masque, sa profondeur normalisée, son contraste au parent, sa dynamique, sa sphéricité et son extension. La dynamique est définie comme l’étendue des niveaux de la sous-arborescence, et non par la hauteur signée usuelle, qui dépend du sens du contraste et casserait l’auto-dualité ; les tests le vérifient.

La remontée de branche est notre contribution propre. Le nœud propre d’un voxel, la plus petite forme qui le contient, reste un objet local : pour un voxel cortical, c’est un fragment de gyrus. L’information utile est plus haut dans la branche. Nous fixons donc quatre seuils d’aire — 100, 1 000, 10 000 et 100 000 voxels — et, pour chacun, nous remontons la branche du voxel jusqu’au premier ancêtre dont l’aire atteint le seuil, dont nous lisons cinq attributs. Avec les six attributs du nœud propre, cela fait $2 \times (6 + 4 \times 5) = 52$ colonnes pour les deux modalités. Le voxel dispose ainsi d’une description de son contexte à quatre échelles anatomiques, du fragment de gyrus au lobe entier, pour zéro paramètre appris : les seuils sont fixés a priori et les ancêtres sont lus sur l’arbre du sujet lui-même.

Le calcul ne coûte qu’une passe sur les nœuds. Comme l’aire croît d’un nœud vers son parent, le premier ancêtre d’aire suffisante obéit à la récurrence

$$a_T(n) = \begin{cases} n & \text{si } \text{aire}(n) \geq T \\ a_T(\text{parent}(n)) & \text{sinon} \end{cases}$$

qui se résout pour tous les nœuds à la fois, par sauts de pointeurs vectorisés, en un temps linéaire en nombre de nœuds. Le coût ne dépend ni du nombre de voxels par nœud ni de la profondeur de l'arbre. La figure 3b se lit directement comme cette récurrence : l'ordonnée étant l'aire, l'ancêtre retenu pour un seuil est simplement le premier nœud de la branche au-dessus de la ligne du seuil.

La remontée de branche apporte, à structure d'arbre identique, +0,0035 de Dice moyen sur la variante qui ne lit que le nœud propre, avec 10 sujets améliorés sur 10 et $p = 0,002$. Le bloc morphologique dans son ensemble apporte +0,0102 sur la configuration sans morphologie, également sur 10 sujets sur 10. Le détail est en section 5.

3.4 Classifieur et post-traitement

Le classifieur est une régression logistique multinomiale. À F colonnes elle coûte exactement $3(F + 1)$ poids, soit 456 pour les 151 colonnes de la configuration finale. Deux raisons à ce choix, et la seconde compte autant que la première. C'est le plus petit modèle qui sache encore combiner linéairement des descripteurs d'échelles et d'unités différentes ; c'est surtout un modèle dont le décompte ne se discute pas, là où un modèle à base d'arbres obligerait à convenir d'abord de ce que coûte un nœud. La régularisation vaut $C = 1$ et le nombre d'itérations 300, tous deux fixés a priori et jamais choisis sur les labels. L'optimiseur en réclame 319 pour converger complètement : l'écart a été mesuré sur un pli, le Dice est identique à la quatrième décimale et la norme des poids passe de 10,33 à 10,19.

L'auto-contexte, et le piège qu'il tend. Le classifieur décide voxel par voxel. Le bloc F lui donne déjà un voisinage, mais sur les intensités ; l'auto-contexte (Tu et Bai 2010) lui en donne un sur les décisions. Un premier étage produit une carte de probabilités, on en lit la moyenne dans des voisinages gaussiens de 1, 2 et 4 mm, et un second étage reçoit les colonnes d'origine plus ces neuf colonnes-là. Un voxel isolément ambigu redevient décidable si tout ce qui l'entoure penche déjà d'un côté : c'est exactement ce qui manque en phase isointense.

Le piège est dans l'entraînement du second étage. Si les cartes de probabilités qu'il voit ont été produites par le premier étage sur ses propres données d'entraînement, elles sont anormalement bonnes — le premier étage a déjà vu ces voxels. Le second apprend alors à faire au premier une confiance que la qualité réelle ne justifie pas, et l'ensemble se dégrade à l'inférence. La parade est une validation croisée interne aux neuf sujets d'entraînement du pli courant : les colonnes de contexte d'un sujet sont toujours produites par un modèle qui ne l'a jamais vu. Le sujet laissé dehors par la boucle externe n'entre nulle part, et la partition interne ne concerne que les neuf autres.

Ce que cela coûte est explicite : les deux étages sont transportés à l'inférence, soit $3(F + 1) + 3(F + 10)$ paramètres, 939 pour $F = 151$. Les modèles des plis internes, eux, sont jetés une fois les colonnes de contexte fabriquées ; ils ne sont pas transportés et ne comptent pas. C'est le seul point de la convention où un lecteur pourrait vouloir trancher autrement, et il est écrit ici pour qu'il puisse le faire.

Le post-traitement, à zéro paramètre. Trois défauts découlent mécaniquement d'une décision prise voxel par voxel : du bruit poivre-et-sel dans les régions homogènes, des composantes minuscules isolées, et des contacts directs entre substance blanche et liquide céphalo-rachidien. Le dernier est le plus intéressant, parce qu'il est anatomiquement impossible : le ruban cortical s'interpose partout entre les deux. Trois étapes les corrigent — lissage gaussien des probabilités à $\sigma = 1$ mm en convolution normalisée, suppression des composantes connexes de moins de 30 mm^3 avec réattribution à la meilleure classe suivante, et interdiction de toute 6-adjacence entre substance blanche et LCR, le voxel le moins sûr des deux passant en matière grise. Aucun de ces seuils n'est calibré sur les labels : ils viennent de l'échelle du voxel et de l'anatomie. Le post-traitement ajoute donc zéro paramètre appris, et c'est ce qui le rend

intéressant dans un projet dont le critère est le nombre de paramètres. Un seuil qui aurait été ajusté sur les labels d’entraînement, lui, devrait être compté.

La sélection de colonnes n’est pas gratuite. On peut ne garder que les K colonnes de plus grand poids et réajuster. Le décompte passe alors de $3(F + 1)$ à $3(K + 1) + K$, car les indices retenus sont ajustés sur les sujets d’entraînement et doivent être transportés : sans eux, on ne sait pas quelles colonnes présenter au modèle. Ils tombent donc sous la règle de la section 3.5 et sont comptés, un entier par colonne. À $K = 40$, cela fait 163 paramètres contre 456. Le rapport devra présenter le gain net, pas la seule réduction du nombre de poids.

Ce que les trois donnent, mesuré. Les résultats complets sont en section 5 ; voici ce qu’ils disent de ces trois mécanismes, y compris quand ils disent non.

L’auto-contexte gagne, et nettement : 0,8399 contre 0,8276, soit +0,0122 de Dice sur les dix sujets, dix sujets améliorés sur dix, $p = 0,002$ brut et 0,027 après Holm. C’est le même ordre de gain que l’ajout de tous les blocs de descripteurs à la configuration de référence, pour un peu plus du double de paramètres — 939 contre 456. Il améliore aussi les deux métriques de distance, ASD et MHD, ce qui n’allait pas de soi.

La sélection à 40 colonnes coûte ce qu’elle prétend économiser, et le front de Pareto de la figure 4 est là pour arbitrer : 0,8036 pour 163 paramètres, soit −0,0240 de Dice contre la configuration finale, zéro sujet amélioré sur dix. C’est une dégradation franche et systématique, mais elle achète un facteur 2,8 sur le décompte. Ce n’est donc pas un échec : c’est le point le plus frugal de notre front, et le seul argument valable pour ou contre est celui du compromis, pas celui du Dice seul.

Le post-traitement, lui, ne marche pas, et l’erreur est instructive. Le lissage et le nettoyage des composantes coûtent −0,0031 de Dice, trois sujets améliorés sur dix, non distinguable du bruit ; la contrainte topologique ajoutée par-dessus coûte encore −0,0011, zéro sujet amélioré sur dix, et cette dégradation-là est parfaitement systématique. La raison de la seconde est une erreur d’anatomie de notre part, pas un défaut d’implémentation. Nous avons posé que le ruban cortical s’interpose partout entre substance blanche et LCR. C’est vrai en surface. C’est faux aux ventricules, où la substance blanche périventriculaire borde directement le LCR ventriculaire, sans matière grise entre les deux. La contrainte force donc de la matière grise le long de toute la paroi ventriculaire, où il n’y en a pas. Restreinte au LCR sous-arachnoïdien, elle resterait défendable ; appliquée partout, elle est fausse, et la mesure la punit exactement là où on l’attendrait.

Quant au lissage, l’explication tient sans doute à ce que les blocs B et F fournissent déjà un voisinage multi-échelle : la carte de probabilités est régularisée en amont, et lisser une seconde fois érode les structures fines, sulci et frontières corticales. Il faut noter que sur l’ASD, seule métrique où il gagne, le lissage donne la meilleure valeur de toutes les configurations — il rapproche les surfaces tout en dégradant le recouvrement, ce qui est cohérent avec cette lecture.

Les trois mécanismes sont couverts par la suite de tests, y compris un test d’intégration qui fait tourner la boucle leave-one-out complète sur des sujets de synthèse, et un test de régression sur un blocage de la contrainte topologique que seules les vraies données avaient révélé.

3.5 Convention de comptage des paramètres

Ce qui compte comme paramètre appris

La règle. Est un paramètre appris toute quantité ajustée sur les sujets d’entraînement et réutilisée telle quelle à l’inférence — autrement dit, toute quantité qu’il faudrait sérialiser pour segmenter un nouveau sujet.

Comptent : les poids et les biais du classifieur, sans exception, et pour chaque étage s’il

y en a plusieurs ; les indices des colonnes retenues par une sélection ; toute statistique de normalisation estimée sur le train et figée ; tout seuil de post-traitement qui serait calibré sur les labels.

Ne comptent pas : les statistiques recalculées sur le sujet courant à l'inférence, z-score et médiane intra-masque, rangs percentiles, moyenne et écart-type par colonne ; les hyperparamètres fixés a priori, sigmas des gaussiennes, seuils d'aire de l'arbre des formes, niveaux de quantification, rayons de voisinage, seuils du post-traitement ; la structure des descripteurs elle-même, dont la suite de tests vérifie mécaniquement qu'aucun n'a de paramètre appris.

Le point qui décide de tout est la standardisation. Elle est intra-sujet : la moyenne et l'écart-type de chaque colonne sont recalculés sur le masque cérébral du sujet qu'on est en train de segmenter, à l'entraînement comme à l'inférence. Elle ne mémorise donc rien du jeu d'entraînement, et segmenter un nouveau sujet ne demande de transporter aucune de ces valeurs : c'est le même statut qu'un filtre gaussien ou qu'un calcul d'aire.

Un jury peut être en désaccord avec cette frontière, et il doit trouver son propre chiffre ici plutôt que d'avoir à le reconstituer. **Selon la convention inverse, où le scaler serait compté, la configuration finale passe de 456 à 758 paramètres :** 2×151 valeurs de plus, une moyenne et un écart-type par colonne.

Et c'est ici que la lecture en ordres de grandeur retenue en section 2 montre son second mérite, qui n'est pas cosmétique. **Changer de convention déplace le ratio brut de -40% . Il ne déplace pas la tranche du tout :** 456 et 758 sont l'un et l'autre à quelques centaines, tranche 10^2 . Un désaccord sur la frontière entre « paramètre appris » et « opération » ferait donc basculer un classement fondé sur le ratio brut, et ne changerait rigoureusement rien à un classement fondé sur les ordres de grandeur. Dans les deux cas, quatre tranches séparent notre modèle du million et demi de paramètres de la méthode classée première.

C'est la raison de fond pour laquelle nous ne demandons pas au lecteur d'adhérer à notre convention. À la granularité où l'argument se joue, elle n'a pas à être tranchée.

4 Protocole expérimental

Leave-one-out. Dix plis sur les dix sujets annotés : à chaque pli, neuf sujets entraînent et le dixième est segmenté entièrement. Les graines sont fixées, la graine d'échantillonnage dérive du numéro du sujet de test, et une seule commande reproduit n'importe quel résultat du rapport, `python -m src.cli run experiments/<config>.yaml`, qui écrit un JSON dans `results/`. Tous les chiffres du rapport sont régénérés depuis ces JSON par `make report-assets` ; aucun n'est recopié à la main.

Le contrôle anti-fuite. C'est la propriété la plus critique du protocole, et elle est vérifiée mécaniquement plutôt que par relecture. Chaque bloc de descripteurs est calculé trois fois sur le même sujet : avec la vraie carte de labels, avec une carte permutée où les tissus ont changé d'étiquette, et sans aucune carte, comme sur les treize sujets de test. Le test exige que les trois sorties soient identiques bit à bit. Un bloc qui lirait la vérité terrain, même indirectement, échouerait immédiatement. Un second test vérifie qu'aucun bloc ne garde d'état d'un sujet à l'autre.

Métriques. Les trois du challenge, et toutes les trois rapportées : Dice, distance de surface moyenne (ASD) et distance de Hausdorff modifiée (MHD). Sur la MHD, une précision s'impose : deux définitions circulent, et nous retenons en interne le 95^e percentile des distances de surface symétriques. Le retour du serveur du challenge montre que **ce n'est pas la sienne** — nos MHD

internes valent de 1 à 3 mm là où le serveur en rend de 8 à 13 mm sur les mêmes segmentations. Nos MHD internes ne se comparent donc qu’entre elles ; toute comparaison de MHD avec le challenge se fait sur les valeurs rendues par le serveur, données en section 5. Elles sont calculées par classe et par sujet, jamais agrégées sur les voxels de plusieurs sujets, et le fond n’est jamais évalué. Le section 5 donne le Dice dans le corps du texte et les distances dans un tableau séparé : le Dice mesure un recouvrement de volume, les distances mesurent une erreur de frontière, et une méthode peut gagner sur l’un sans gagner sur l’autre — ce qui arrive effectivement dans nos résultats.

Protocole statistique. Dix sujets, c’est peu, et un écart de quelques millièmes de Dice peut n’être que du bruit. Le même sujet passant dans toutes les configurations, toutes les comparaisons sont appariées. Chacune rapporte le delta moyen et son écart-type inter-sujets, le test des rangs signés de Wilcoxon bilatéral, la taille d’effet — d de Cohen apparié et δ de Cliff, non paramétrique — et le nombre de sujets améliorés sur dix. Ce dernier mérite sa justification : à $n = 10$ l’amplitude d’un gain est bruitée, mais sa systématisme ne l’est pas, et un gain porté par un seul sujet n’est pas un gain. Un effet est déclaré distinguable du bruit si la p-valeur ajustée est inférieure à 0,05 et si au moins huit sujets sur dix vont dans le même sens ; le critère est symétrique, une dégradation systématique reste un résultat.

Les quatorze comparaisons sont déclarées à l’avance — chacune au moment où la configuration qu’elle concerne a été figée dans `experiments/`, avant son exécution — et corrigées de la multiplicité par la méthode de Holm appliquée à la famille entière. Corriger sur un sous-ensemble donnerait une correction plus permissive que la vérité ; c’est l’erreur à ne pas commettre quand on ajoute une configuration en cours de route. Le verdict est rendu sur la p-valeur ajustée, jamais sur la brute. Avec $n = 10$ la plus petite p-valeur atteignable vaut 0,002 : sur une famille de quatorze elle devient 0,027, et tous les gains que nous revendiquons la franchissent. La correction ne nous coûte donc aucun résultat — raison de plus pour l’appliquer plutôt que d’argumenter qu’elle serait facultative.

5 Résultats

Toutes les valeurs de cette section viennent de `report/assets/`, régénéré depuis les JSON de `results/` par `make report-assets`. Aucune n’est écrite à la main.


5.1 Ablation

Le tableau 2 donne les douze configurations. Trois lectures s’en dégagent, et la troisième est celle qui compte.

D’abord, **le contexte non local paye et la description locale plafonne**. Passer de A+B+C au bloc morphologique gagne +0,0102 de Dice sur dix sujets sur dix ; la remontée de branche en ajoute +0,0035, également sur dix sujets sur dix. Les deux survivent à la correction de Holm. À l’inverse, les raffinements purement locaux — filtres de grain, quantification par rang — ne produisent aucun effet distinguable. C’est exactement ce que la phase isointense laissait attendre : ce qui manque au voxel n’est pas dans son voisinage immédiat.

Ensuite, **l’auto-contexte prolonge le même mouvement**, et c’est cohérent : il ajoute du contexte non local, non plus sur les intensités mais sur les décisions. Il porte le Dice à 0,8399, gagne sur les dix sujets, et améliore les trois métriques à la fois — seul point du tableau à obtenir simultanément le meilleur Dice, le meilleur ASD et le meilleur MHD.

Enfin, **deux mécanismes échouent, et nous les gardons dans le tableau**. Le post-traitement dégrade ; l’arbre des formes n’apporte rien contre la paire max-tree / min-tree. Les section 6 y revient.



Le losange et les carrés sont évalués sur les MÈMES 13 sujets de test par le serveur des organisateurs : ils se comparent directement. Le front en trait plein est un leave-one-out sur les 10 sujets annotés — il sert à comparer nos configurations entre elles, pas au challenge.

Figure 4. Front de Pareto dans le plan (paramètres appris, Dice moyen), abscisse logarithmique. Les deux références publiées sont les seules méthodes du challenge pour lesquelles on dispose à la fois d’un Dice officiel et d’un compte de paramètres publié ; aucune méthode dont il faudrait estimer le décompte n’est placée dans le nuage. Le losange est notre score officiel, rendu par le serveur sur les mêmes treize sujets que les carrés : lui seul se compare directement à eux. Le front en trait plein, lui, est un leave-one-out sur les dix sujets annotés et ne sert qu’à situer nos configurations les unes par rapport aux autres.

Tableau 2. Ablation en leave-one-out sur les dix sujets annotés. Dice moyen par tissu ; les écarts-types inter-sujets, qui valent de 0,009 à 0,018 selon le tissu, sont omis ici pour la lisibilité et figurent dans `report/assets/ablation.md` avec l’ASD et la MHD. Les quatorze comparaisons appariées sont dans `report/assets/stats.md`.

configuration	param.	LCR	SG	SB	Dice moyen
A+B+C, sans morphologie (référence)	252	0,851	0,805	0,761	0,8055
palier 0 : max-tree + min-tree	324	0,866	0,813	0,767	0,8156
palier 1 : + remontée de branche	564	0,868	0,818	0,772	0,8191
palier 2 : arbre des formes + remontée	408	0,866	0,814	0,766	0,8154
palier 3 : + filtres de grain	426	0,866	0,814	0,766	0,8154
palier 2, quantification 64 niveaux	408	0,866	0,814	0,765	0,8149
palier 2, quantification par rang	408	0,862	0,813	0,766	0,8136
sélection des 40 meilleures colonnes	163	0,861	0,804	0,746	0,8036
configuration finale : tous les blocs	456	0,881	0,825	0,777	0,8276
finale + lissage et nettoyage	456	0,876	0,825	0,773	0,8246
finale + contrainte topologique	456	0,877	0,823	0,770	0,8235
finale + auto-contexte	939	0,891	0,834	0,795	0,8399

5.2 Le front de Pareto

La figure 4 porte l’argument central. Notre front s’étend de 163 à 939 paramètres, et sa forme est celle qu’on attend : le Dice croît d’abord vite, puis se tasse. Le losange est notre score officiel, et c’est lui qui autorise la comparaison : **0,8445 contre 0,9283 pour la méthode classée première, soit 91 % de son Dice, sur les mêmes treize sujets et par le même évaluateur, avec 10^2 paramètres contre 10^6 .**

Traduit dans le critère retenu en section 2, l’énoncé ne dépend d’aucun décompte fin : nous sommes quatre tranches d’ordre de grandeur en dessous pour un Dice qui vaut neuf dixièmes du sien. C’est le seul sens dans lequel nous prétendons faire mieux — par tranche, pas en Dice absolu, où nous sommes nettement derrière. Et à l’intérieur de notre propre tranche, où le critère est muet, c’est le Dice qui désigne l’auto-contexte.

5.3 Le score officiel du challenge

Nous avons soumis au serveur des organisateurs la configuration à auto-contexte, réentraînée sur les dix sujets annotés — le régime normal d’un modèle qu’on livre, puisqu’il n’y a plus de raison d’en retenir un. Le tableau 3 donne ce que le serveur a rendu sur les treize sujets de test, dont la vérité terrain ne nous est jamais montrée.


Tableau 3. Score officiel rendu par le serveur du challenge sur les treize sujets de test, pour la configuration à auto-contexte et ses 939 paramètres. Écarts-types inter-sujets. Les MHD sont celles du serveur, calculées avec sa définition et non la nôtre (section 4), et ce sont donc les seules qui se comparent au classement. Valeurs par sujet dans `results/official_test.json`.

	LCR	SG	SB	moyenne
Dice	$0,8992 \pm 0,0111$	$0,8375 \pm 0,0124$	$0,7968 \pm 0,0194$	0,8445
ASD (mm)	0,297	0,614	0,798	
MHD (mm)	10,77	8,30	12,77	

Le premier enseignement porte sur notre propre protocole. Notre leave-one-out annonçait 0,8399 ; le serveur rend 0,8445, soit +0,0047. L’écart est du bon côté, et par tissu : +0,008 sur le LCR, +0,004 sur la matière grise, +0,002 sur la blanche. Autrement dit **notre estimation interne n’était pas optimiste**, ce qui est le risque habituel d’une validation croisée sur dix sujets. Elle était même légèrement pessimiste, dans la proportion qu’on attend d’un modèle entraîné sur dix sujets plutôt que neuf. C’est la meilleure validation que nous puissions offrir du protocole de la section 4, et elle n’était pas acquise d’avance.

Le second porte sur la comparaison. À 0,8445, nous atteignons 91 % du Dice de la méthode classée première du challenge, 90,7 % de celui de BCH_CRL_IMAGINE et 92,3 % de celui de HD — toutes des méthodes en 10^6 ou 10^7 paramètres. Nous sommes derrière chacune d’elles en Dice absolu, sans ambiguïté et sans nuance à apporter. Le seul énoncé que nous défendons est celui du compromis : **neuf dixièmes du Dice, quatre tranches d’ordre de grandeur plus bas.**

Un point mérite d’être relevé plutôt que passé sous silence. Le tableau public du challenge donne six équipes ; la moins bien classée des six obtient 0,859 de Dice moyen, et nous en atteignons 98 %. Sur la matière grise, le tissu le plus difficile à cet âge, l’écart avec elle tombe à un demi-point — 0,8375 contre 0,842. C’est sur la substance blanche que le retard se creuse vraiment, à 0,797 contre 0,90 et au-delà pour le haut du classement. C’est cohérent avec ce que montre la figure 6 : notre erreur est un liseré de frontière, et la substance blanche est le tissu dont la frontière est la plus longue et la moins contrastée.



En rouge, les étapes que le protocole de la section 4 déclare distinguables du bruit (Wilcoxon apparié, corrigé de Holm sur la famille entière). L'axe du panneau (a) est tronqué : les écarts valent quelques millièmes de Dice. Les intervalles sont calculés sur $n = 10$ sujets par la loi de Student : ils décrivent la précision de la moyenne et ne décident de rien. Un intervalle qui exclut zéro sans que l'étape soit rouge signale une divergence entre l'intervalle et le test déclaré : c'est le test qui tranche.

Figure 5. Ablation en barres. (a) Dice absolu de chaque configuration, intervalle de confiance à 95 % de la moyenne sur les dix sujets : tous les intervalles se chevauchent. (b) Delta apparié contre l'étape précédente : la variabilité inter-sujets s'annule dans la différence et des effets nets apparaissent. En accent, les étapes que le protocole de la section 4 déclare distinguables du bruit.

5.4 Ce que valent les intervalles, et ce que valent les tests

La figure 5 vaut moins pour ses barres que pour le contraste entre ses deux panneaux. Lues en valeurs absolues, les configurations sont indiscernables : sur dix sujets, l'écart-type inter-sujets vaut environ 0,011 de Dice, soit trois fois le plus gros effet que nous mesurons. Un lecteur qui s'arrêterait au panneau (a) conclurait, à tort, qu'aucune étape ne fait rien. Le panneau (b) montre pourquoi c'est faux : le même sujet passant dans toutes les configurations, la variabilité inter-sujets disparaît de la différence, et l'intervalle de +0,0122 pour l'auto-contexte exclut zéro très largement.

C'est le seul argument statistique de ce rapport, et il justifie à lui seul que toutes nos comparaisons soient appariées. Un cas mérite d'être signalé plutôt que caché : pour le palier 2 contre le palier 1, l'intervalle de confiance de Student exclut zéro alors que le test de Wilcoxon déclaré ne conclut pas ($p = 0,064$ brut, 0,258 après Holm). Les deux outils divergent sur dix sujets. C'est le test déclaré qui tranche, et la figure le signale.

5.5 Budget de frugalité

Le modèle entier tient dans **2,5 kilo-octets sur disque** pour la configuration finale, et le temps d'inférence est de l'ordre de la seconde par volume. L'extraction des descripteurs domine largement le coût, et à l'intérieur de l'extraction c'est le bloc gaussien puis le bloc morphologique qui dominant. La frugalité de cette approche est donc paramétrique et mémorielle bien plus que calculatoire : nous ne prétendons pas être rapides, nous prétendons ne rien mémoriser.

Les mesures détaillées sont dans `report/assets/frugality.md`. **Attention à ne pas les lire en travers** : elles ont été produites sur deux machines différentes, ce que l'asset signale ligne par ligne. Seules les mesures issues de la même machine se comparent en secondes.

Le résultat sur la quantification à 64 niveaux est négatif, et nous le corrigeons ici.

Nous avons présenté la réduction à 64 niveaux comme un levier de frugalité. La mesure, faite sur une seule et même machine pour les deux variantes, ne montre aucune économie : 79,9 s contre 80,2 s d'extraction par sujet, même empreinte mémoire du bloc morphologique à 192 Mo, même taille de modèle à 3,9 ko. Et elle coûte -0,0005 de Dice, dégradation faible mais systématique — neuf sujets sur dix, $p = 0,049$ après Holm. Une option qui coûte un peu et ne rapporte rien de mesurable n'est pas un levier de frugalité : c'est une option à ne pas prendre, et nous ne la prenons pas.




Figure 6. Sujet le mieux et le moins bien segmentés du leave-one-out, avec leur carte d’erreur. La coupe est choisie par la même règle pour les deux — celle qui contient le plus de voxels du masque — de façon qu’aucun des deux ne soit montré sous un jour choisi. La carte d’erreur est colorée par le tissu de la vérité terrain, donc par ce que la prédiction a manqué.

5.6 Le meilleur et le pire sujet

La figure 6 montre les deux extrêmes. Le sujet 8 obtient 0,8506, le sujet 2 0,8215 : l’écart entre le meilleur et le pire vaut 0,029 de Dice, soit plus du double du gain qu’apporte l’auto-contexte. **La variabilité entre sujets domine donc largement la différence entre nos configurations**, ce qui est la justification empirique de tout le protocole apparié de la section 4.

Le pire cas mérite d’être regardé plutôt qu’écarté. Sur le sujet 2, l’erreur ne se concentre pas dans une région particulière : elle est distribuée le long de toute l’interface entre substance grise et substance blanche, en un liseré d’un à deux voxels. Ce n’est pas un échec de localisation, c’est un flou de frontière — exactement ce que la phase isointense prédit, et exactement ce que le Dice pénalise le plus sur des structures aussi minces que le ruban cortical. Le tissu le plus touché est la substance blanche, à 0,764 contre 0,796 pour le meilleur sujet ; le LCR, dont la frontière est nettement plus contrastée, reste à 0,886.

Nous ne voyons dans le T1 du sujet 2 rien qui le distingue franchement des autres, ni artefact ni mouvement visible, et nous n’avons donc pas d’explication assurée à son rang. Avec dix sujets, un dernier de classement à trois centièmes du premier n’appelle de toute façon pas d’explication : c’est l’amplitude normale de la variabilité inter-sujets que la figure 5 montre par ailleurs.

6 Discussion

Ce qui marche, et pourquoi. Le fil conducteur de tous nos gains est le même : l’information qui manque au voxel isolé est non locale. Le bloc morphologique, la remontée de branche vers les ancêtres, et l’auto-contexte gagnent tous les trois, chacun sur dix sujets sur dix ; les raffinements locaux ne gagnent rien. C’est la prédiction directe de la figure 1 de l’introduction : à six mois,

l'intensité d'un point ne sépare pas les tissus, et un voisinage de quelques millimètres non plus.

Le résultat négatif sur l'auto-dualité. Nous attendions de l'arbre des formes qu'il fasse mieux que la paire max-tree / min-tree, puisqu'il produit la même information dans une structure unique. Il divise effectivement par deux le nombre de colonnes à attributs identiques — 135 contre 187 — exactement comme la théorie le prédit. Mais le Dice ne bouge pas de façon distinguable : $-0,0002$ contre le palier 0, quatre sujets améliorés sur dix, $p = 0,625$. Contre le palier 1, l'écart de $-0,0037$ ne franchit pas non plus notre seuil.

Nous n'avons pas d'explication certaine et nous préférons le dire. L'hypothèse que nous trouvons la plus probable est que le classifieur linéaire ne tire aucun bénéfice de la compacité : deux colonnes redondantes lui coûtent deux poids, pas de la performance, et la régularisation absorbe la redondance. Le gain de l'auto-dualité serait alors réel mais paramétrique — moins de colonnes pour le même Dice, donc un meilleur point sur le front — et non qualitatif. Le tableau 2 est compatible avec cette lecture : le palier 2 fait aussi bien que le palier 1 avec 408 paramètres au lieu de 564.

Le résultat négatif sur le post-traitement, et l'erreur d'anatomie. La contrainte topologique dégrade systématiquement, et nous savons pourquoi : nous avons posé que le ruban cortical s'interpose partout entre substance blanche et LCR, ce qui est vrai en surface et faux aux ventricules. C'est une erreur de notre part, pas un défaut de la méthode, et elle suggère sa propre correction : restreindre la contrainte au LCR sous-arachnoïdien, en excluant les composantes ventriculaires. Nous ne l'avons pas fait faute de temps, et nous ne revendiquons donc rien sur ce point.

Le cas du lissage est moins net. Il dégrade le Dice de $0,0031$, non distinguable du bruit, mais il donne la meilleure ASD de toutes les configurations. Autrement dit il rapproche les surfaces tout en dégradant le recouvrement volumique — ce qui est cohérent avec l'idée qu'il érode les structures fines, sulci et frontières corticales, déjà régularisées en amont par les blocs gaussien et contexte.

Le compromis de la sélection de colonnes. Passer à 40 colonnes coûte $-0,0240$ de Dice et divise le décompte par 2,8. Nous ne tranchons pas : c'est précisément ce qu'un front de Pareto sert à ne pas trancher à la place du lecteur. Nous signalons seulement que le décompte correct inclut les 40 indices retenus, sans quoi la sélection paraîtrait deux fois plus rentable qu'elle ne l'est.

Limites. Nous les énonçons sans atténuation. Dix sujets annotés seulement pour la mise au point : tout écart inférieur à $0,005$ de Dice est hors de portée de nos comparaisons internes, et toutes nos ablations partagent cette limite. Le score officiel, lui, ne la partage pas — il est mesuré sur treize sujets par l'évaluateur du challenge — mais il ne porte que sur une seule configuration : nous n'avons pas de score officiel pour les autres points du front, et nous n'en revendiquons donc aucun. Les hyperparamètres des blocs sont fixés a priori et non validés dans le pli ; ils ne sont pas ajustés sur les données, mais un jury peut objecter qu'ils incorporent une connaissance du domaine acquise ailleurs. Enfin, la quantification linéaire du bloc morphologique nous fait perdre l'invariance au contraste : seule l'invariance affine subsiste, et nous l'avons dit en section 3.3 plutôt que de revendiquer une propriété que nous n'avons plus.

Pistes. Trois nous paraissent valoir le coup, dans cet ordre. Restreindre la contrainte topologique à la surface corticale, puisque l'échec est compris. Empiler un troisième étage d'auto-contexte, puisque le deuxième gagne autant que tous les blocs de descripteurs réunis. Et calculer l'arbre des formes conjointement sur T1 et T2 plutôt que modalité par modalité, ce qui rendrait au bloc morphologique le comportement croisé qui fait toute la valeur du bloc A.

7 Conclusion

Sur la segmentation en trois tissus de cerveaux de nourrissons en phase isointense, une régression logistique lisant des descripteurs géométriques et hiérarchiques calculés à la volée atteint un Dice moyen de 0,8399 avec 939 paramètres appris, et de 0,8036 avec 163 — deux configurations de la même tranche, 10^2 . Soumise au serveur du challenge, la première obtient officiellement 0,8445 sur les treize sujets de test, contre 0,9283 pour la méthode classée première, qui est en 10^6 : **91 % de son Dice, quatre tranches d'ordre de grandeur plus bas**, sur les mêmes sujets et par le même évaluateur. La comparaison porte sur des sujets différents et se lit en ordre de grandeur ; nous ne la présentons pas autrement.

Ce que ces chiffres soutiennent n'est pas que la frugalité vaut mieux, mais qu'une part substantielle de ce que des millions de poids apprennent peut être remplacée par des descripteurs non appris, à condition qu'ils soient non locaux. Nos gains viennent tous de là, et nos échecs — l'auto-dualité sans gain de Dice, la contrainte topologique fondée sur une anatomie fausse, la quantification qui ne fait économiser rien — viennent tous d'ailleurs.

Références

- Breen, Edmond J., et Ronald Jones. 1996. « Attribute Openings, Thinnings, and Granulometries ». *Computer Vision and Image Understanding* 64 (3): 377-89.
- Géraud, Thierry, Edwin Carlinet, Sébastien Crozet, et Laurent Najman. 2013. « A Quasi-linear Algorithm to Compute the Tree of Shapes of n -D Images ». In *Mathematical Morphology and Its Applications to Signal and Image Processing (ISMM)*, 7883:98-110. Lecture Notes in Computer Science. Springer.
- Monasse, Pascal, et Frédéric Guichard. 2000. « Fast Computation of a Contrast-Invariant Image Representation ». *IEEE Transactions on Image Processing* 9 (5): 860-72.
- Perret, Benjamin, Giovanni Chierchia, Jean Cousty, Silvio Jamil F. Guimarães, Yukiko Kenmochi, et Laurent Najman. 2019. « Higura: Hierarchical Graph Analysis ». *SoftwareX* 10: 100335.
- Salembier, Philippe, Albert Oliveras, et Luis Garrido. 1998. « Antiextensive Connected Operators for Image and Sequence Processing ». *IEEE Transactions on Image Processing* 7 (4): 555-70.
- Tu, Zhuowen, et Xiang Bai. 2010. « Auto-Context and Its Application to High-Level Vision Tasks and 3D Brain Image Segmentation ». *IEEE Transactions on Pattern Analysis and Machine Intelligence* 32 (10): 1744-57.
- Wang, Li, Dong Nie, Guannan Li, et al. 2019. « Benchmark on Automatic Six-Month-Old Infant Brain Segmentation Algorithms: The iSeg-2017 Challenge ». *IEEE Transactions on Medical Imaging* 38 (9): 2219-30. <https://doi.org/10.1109/TMI.2019.2901712>.